

Inteligencia Artificial

Q-learning

Sergio Yovine

Universidad ORT Uruguay

yovine@ort.edu.uy

13 de mayo de 2024

Repaso: Estimación del valor de una policy

Inicializar: para todo $s \in S$

$$Utilidades(s) \leftarrow \{\}$$

Repetir:

Generar un episodio según π : $s_0, a_0, r_1, s_1, \dots, s_{T-1}, a_{T-1}, r_T, s_T$

$$G \leftarrow 0$$

Para cada paso del episodio, $t = T - 1, T - 2, \dots, 0$:

$$G \leftarrow \gamma G + r_{t+1}$$

Si $s_t \notin \{s_0, \dots, s_{t-1}\}$: (* primera visita *)

Agregar G a $Utilidades(s_t)$

$$V(s_t) \leftarrow promedio(Utilidades(s_t))$$

$V(s)$ converge a $V_\pi(s)$ (pero sólo para los estados visitados).

Se puede estimar Q y π^* (de manera similar a P.I)

Análisis de MC

Luego de k episodios que visitaron $s \in S$, el valor estimado de s es:

$$V = \frac{G^{(1)} + \dots + G^{(k)}}{k}$$

donde $G^{(i)}$ es la utilidad observada en la i -ésima iteración.

Al terminar el episodio $k + 1$, el valor estimado de s es:

$$\begin{aligned} V' &= \frac{G^{(1)} + \dots + G^{(k)} + G^{(k+1)}}{k+1} = \frac{kV + G^{(k+1)}}{k+1} \\ &= \frac{kV}{k+1} + \frac{G^{(k+1)}}{k+1} + \frac{V}{k+1} - \frac{V}{k+1} \\ &= V + \frac{1}{k+1} \left(G^{(k+1)} - V \right) \end{aligned}$$

α -MC

La actualización de la estimación tiene la siguiente forma:

$$NuevaEst \leftarrow ViejaEst + \alpha \left(Objetivo - ViejaEst \right)$$

$\alpha \in (0, 1)$ es la *tasa de actualización*.

La actualización de la estimación en α -MC es:

$$V(s_t) \leftarrow V(s_t) + \alpha \left(G_t - V(s_t) \right)$$

α -MC usa la observación *real* G_t para estimar el valor.

Para calcular G_t se requiere ir hasta el *final* del episodio.

Métodos de Diferencias Temporales: TD(0)

Se actualiza el valor en *cada paso* usando la *estimación* $r_{t+1} + \gamma V(s_{t+1})$

Inicializar $V(s)$ arbitrariamente $\forall s \in S$

Repetir:

 Inicializar s

$done \leftarrow \text{False}$

 Repetir hasta $done$:

$a \leftarrow \pi(s)$

$s', r, done \leftarrow \text{step}(a)$

$V(s) \leftarrow V(s) + \alpha(r + \gamma V(s') - V(s))$

$s \leftarrow s'$

α -MC y TD(0) convergen al mismo valor.

TD(0) suele converger más rápido.

Q-learning (off-policy TD control)

Estimación de la estrategia óptima $\pi^* = \arg \max Q$ basado en TD.

Inicializar $Q(s, a)$ arbitrariamente $\forall s \in S, a \in A(s)$

Repetir:

 Inicializar s

$done \leftarrow \text{False}$

 Repetir hasta $done$:

 Con probabilidad ε hacer: (* estrategia ε -greedy *)

 explore: $a \leftarrow \text{sample}(A(s))$

 exploit: $a \leftarrow \arg \max Q(s, \cdot)$

$s', r, done \leftarrow \text{step}(a)$

$Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma \max Q(s', \cdot) - Q(s, a))$

$s \leftarrow s'$

Bibliografía

Richard Sutton and Andrew Barto. Reinforcement Learning. An Introduction (2nd edition). MIT Press. Cap. 6.1 y 6.5